

# Relatório Técnico

## Planejamento de Testes Veiculares

Case Fictício – Volkswagen

---

### Sumário Executivo

Este relatório apresenta uma solução integrada baseada em **Inteligência Artificial, Otimização Matemática e Simulação Numérica** aplicada ao planejamento de testes veiculares. O objetivo central é minimizar o **Makespan** (tempo total de conclusão dos testes) em múltiplas baias, incorporando explicitamente o **risco de falha** estimado por modelos de *Machine Learning*.

Os resultados demonstram que um agendamento sensível ao risco produz cronogramas mais realistas e robustos frente às incertezas operacionais típicas do ambiente de testes automotivos.

---

### 1. Introdução e Contexto

No desenvolvimento de veículos, a execução eficiente dos testes físicos é um fator crítico de sucesso. Atrasos recorrentes surgem, principalmente, devido a falhas inesperadas que demandam retrabalho, reparos ou repetição de ensaios.

Este estudo de caso aborda três pilares principais:

1. **Predição de Falhas:** uso de dados históricos para estimar a probabilidade de falha de cada teste.
  2. **Otimização de Agendamento:** alocação inteligente dos testes em recursos limitados (baias).
  3. **Análise de Risco:** validação da robustez do cronograma por meio de simulação estocástica.
- 

### 2. Geração e Análise de Dados

Foi construído um *dataset* sintético representando **200 testes veiculares**, com as seguintes variáveis:

#### Variáveis de Entrada (Features)

- `duration` - duração nominal estimada do teste (distribuição normal, média de 120 minutos);
- `priority` - prioridade operacional do teste (escala de 1 a 5);
- `complexity` - nível de complexidade técnica (1 a 3);
- `environment_temp` - temperatura ambiente durante a execução do teste.

#### Variável Alvo (Target)

- `failure` - indicador binário (0 = sucesso, 1 = falha).

A variável de falha foi gerada probabilisticamente a partir de uma função linear das *features*, refletindo um cenário realista onde testes mais longos, complexos e executados sob condições ambientais extremas apresentam maior risco.

---

### 3. Machine Learning: Modelo Preditivo de Falhas

#### 3.1 Metodologia

Foi utilizado um **Random Forest Classifier** para modelar a relação entre as características dos testes e a ocorrência de falhas. O conjunto de dados foi dividido em: - **70%** para treinamento; - **30%** para teste e validação.

#### 3.2 Desempenho do Modelo

O desempenho foi avaliado com métricas adequadas à previsão probabilística:

- **AUC-ROC: 0,6752**

*O modelo apresenta capacidade razoável de discriminar testes propensos à falha.*

- **Brier Score: 0,2067**

*Indica boa calibração entre probabilidades previstas e resultados observados.*

#### 3.3 Importância das Variáveis

A análise de *Feature Importance* indicou que: - **Complexidade e Duração** são os fatores mais relevantes para o risco de falha; - A **temperatura ambiente** exerce influência secundária, porém significativa.

---

## 4. Modelo de Otimização – Agendamento Inteligente

#### 4.1 Formulação do Problema

O problema consiste em alocar **200 testes** em **3 baias de teste**, minimizando o tempo total de conclusão (**Makespan**).

#### 4.2 Estratégia Sensível ao Risco (*Risk-Aware Scheduling*)

Em vez de utilizar apenas a duração nominal dos testes, definiu-se uma **duração esperada ajustada ao risco**, incorporando a probabilidade de falha prevista pelo modelo de *Machine Learning*.

$$\mathbb{E}[T_i] = T_i^{\text{nom}} + p_i^{\text{falha}} \cdot T^{\text{reparo}}$$

Onde: -  $T_i^{\text{nom}}$  é a duração nominal do teste  $i$ ; -  $p_i^{\text{falha}}$  é a probabilidade de falha estimada; -  $T^{\text{reparo}}$  é o tempo médio de reparo, fixado em **60 minutos**.

**Interpretação:** testes com maior risco passam a consumir mais tempo “esperado” no modelo de otimização, reduzindo a chance de gargalos futuros.

### 4.3 Implementação Matemática (MILP)

O problema foi formulado como um modelo de **Programação Linear Inteira Mista (MILP)**.

- **Variáveis de decisão:**  $x_{ij} \in \{0, 1\}$ , indicando se o teste  $i$  é alocado à baia  $j$ .

- **Função Objetivo:**

$$\min C_{\max}$$

- **Restrições:**

$$\sum_{j=1}^3 x_{ij} = 1, \quad \forall i$$

$$\sum_{i=1}^{200} \mathbb{E}[T_i] x_{ij} \leq C_{\max}, \quad \forall j$$

### 4.4 Resultados da Otimização

- **Makespan planejado: 9.386,62 minutos;**
  - O cronograma resultante apresentou distribuição equilibrada de testes críticos e de alto risco entre as baias, conforme visualizado em gráfico de Gantt.
- 

## 5. Simulação Numérica – Monte Carlo

Para validar a robustez do cronograma, foi executada uma **Simulação de Monte Carlo com 2.000 iterações**.

### 5.1 Hipóteses da Simulação

Foram consideradas duas fontes principais de incerteza:

1. **Variabilidade natural da duração:**

$$T_i^{\text{real}} \sim \mathcal{N}(T_i^{\text{nom}}, 0,15 \cdot T_i^{\text{nom}})$$

2. **Eventos de falha:**

$$F_i \sim \text{Bernoulli}(p_i^{\text{falha}})$$

Caso ocorra falha ( $F_i = 1$ ), adiciona-se **60 minutos** ao tempo real do teste.

### 5.2 Resultados Obtidos

A distribuição do tempo total real indicou:

- **Tempo planejado (otimizador):** ~9.387 min;
- **Tempo médio real (simulado):** ~9.584 min;

- Percentil 95 (P95): ~9.896 min.
- 

## 6. Conclusão e Análise Final

A abordagem integrada demonstrou ganhos relevantes para o planejamento de testes veiculares:

1. **Aderência entre plano e realidade:** o tempo planejado pelo otimizador apresentou diferença de apenas ~2% em relação ao tempo médio real simulado.
2. **Gestão de risco:** o uso do P95 como referência operacional permite compromissos de prazo com **95% de confiança**.
3. **Robustez operacional:** a penalização de testes arriscados evitou sobrecarga em uma única baia, mitigando atrasos severos comuns em abordagens determinísticas tradicionais.

Em síntese, a combinação de *Machine Learning*, otimização matemática e simulação estocástica constitui uma estratégia eficaz e escalável para o planejamento avançado de testes automotivos.